

NHÓM 17: PHÁT HIỆN GIỌNG NÓI GIẢ MẠO TRONG TIẾNG VIỆT SỬ DỤNG CÁC ĐẶC TRƯNG ÂM HỌC VÀ THUẬT TOÁN HỌC MÁY

NGUYỄN TIẾN HOAN
VIỆN TRÍ TUỆ NHÂN TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ
24022334
shiba171006@gmail.com

NGUYỄN BÁ HIỂN
VIỆN TRÍ TUỆ NHÂN TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ
24022322
nguyenhiephien9@gmail.com

NGUYỄN THỊ HIỀN
VIỆN TRÍ TUỆ NHÂN TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ
24022321
hien333987@gmail.com

Ngày 2 tháng 6 năm 2026

TÓM TẮT

Các cuộc tấn công lừa đảo sử dụng công nghệ giả mạo giọng nói (Voice Deepfake/Audio Spoofing) đang gia tăng nhanh chóng tại Việt Nam, trong khi các nghiên cứu hiện nay chủ yếu tập trung vào tiếng Anh và chưa khai thác đầy đủ các đặc trưng ngữ âm đặc thù của tiếng Việt [1, 6]. Nghiên cứu này đề xuất Viet-Guard, một hệ thống phát hiện giọng nói giả mạo trong tiếng Việt dựa trên các đặc trưng âm học (MFCC, LFCC, Wav2Vec 2.0) và các thuật toán học máy như SVM, XGBoost và MLP. Bộ dữ liệu thực nghiệm gồm 2.400 tệp âm thanh, bao gồm 1.200 mẫu giọng thật từ VIVOS/VLSP [4] và 1.200 mẫu giọng giả được tổng hợp từ các nền tảng trí tuệ nhân tạo phổ biến. Kết quả thực nghiệm cho thấy mô hình SVM kết hợp đặc trưng LFCC đạt độ chính xác cao nhất là 89,38%. Trên cơ sở đó, các mô hình được kết hợp để đưa ra kết quả dự đoán cuối cùng và được tích hợp vào một ứng dụng web phục vụ phát hiện giọng nói giả mạo.

Từ khóa: Machine Learning, Predictive Modeling, Audio Deepfake

1 GIỚI THIỆU

Trong những năm gần đây, công nghệ tổng hợp và sao chép giọng nói bằng trí tuệ nhân tạo đã phát triển mạnh mẽ, cho phép tạo ra các đoạn âm thanh có mức độ tương đồng cao với giọng nói của con người. Bên cạnh các ứng dụng tích cực, công nghệ này cũng bị lợi dụng để tạo ra các đoạn giọng nói giả mạo nhằm thực hiện các hành vi giả danh và lừa đảo [1, 6]. Tại Việt Nam, các cuộc gọi và tin nhắn thoại sử dụng giọng nói nhân tạo đang trở thành một mối đe dọa đáng kể đối với an ninh thông tin và an toàn tài chính của người dùng.

Bài toán phát hiện giọng nói giả mạo (Audio Spoofing/Voice Deepfake Detection) đã nhận được nhiều sự quan tâm trong cộng đồng nghiên cứu. Tuy nhiên, phần lớn các hệ thống hiện nay được xây dựng và đánh giá chủ yếu trên dữ liệu tiếng Anh [2]. Điều này tạo ra một khoảng

trống nghiên cứu quan trọng đối với tiếng Việt, là ngôn ngữ có hệ thống thanh điệu phong phú và các đặc trưng ngữ âm khác biệt, khiến các mô hình được phát triển cho ngôn ngữ khác khó đạt hiệu quả tối ưu.

Mục tiêu của nghiên cứu này là xây dựng và đánh giá Viet-Guard, một hệ thống phát hiện giọng nói giả mạo trong tiếng Việt dựa trên các đặc trưng âm học và các thuật toán học máy. Bộ dữ liệu thực nghiệm bao gồm giọng nói thật được thu thập từ các bộ dữ liệu VIVOS/VLSP [4] và giọng nói giả được tổng hợp từ các nền tảng trí tuệ nhân tạo phổ biến như FPT.AI, Viettel AI và ElevenLabs. Từ dữ liệu âm thanh, nghiên cứu trích xuất các đặc trưng MFCC, LFCC và biểu diễn ngữ nghĩa từ Wav2Vec 2.0 [3], sau đó huấn luyện và đánh giá các mô hình SVM, XGBoost và MLP.

Các mô hình được kết hợp để đưa ra quyết định phân loại cuối cùng và được tích hợp vào một ứng dụng web cho

phép người dùng tải lên tệp âm thanh và nhận kết quả phân tích theo thời gian thực. Hệ thống này hướng tới việc hỗ trợ phát hiện các trường hợp giả mạo giọng nói trong thực tế.

2 CƠ SỞ LÝ THUYẾT

Phát hiện giả mạo giọng nói (Audio Anti-Spoofing) là bài toán phân loại tín hiệu âm thanh thành hai nhóm: giọng nói tự nhiên (bona fide) và giọng nói giả mạo (spoofed) được tạo ra bằng các kỹ thuật tổng hợp hoặc sao chép giọng nói [1]. Đây là một bài toán quan trọng trong lĩnh vực xử lý tiếng nói và an ninh thông tin, đặc biệt trong bối cảnh các công nghệ tổng hợp giọng nói ngày càng trở nên phổ biến.

Trong các hệ thống phát hiện giọng nói giả mạo, việc trích xuất đặc trưng âm học đóng vai trò then chốt. MFCC (Mel-Frequency Cepstral Coefficients) là một trong những đặc trưng phổ biến nhất, mô phỏng cách tai người cảm nhận tín hiệu âm thanh thông qua thang tần số Mel [5]. Bên cạnh đó, LFCC (Linear Frequency Cepstral Coefficients) sử dụng thang tần số tuyến tính, giúp bảo toàn thông tin ở các dải tần số cao, nơi thường xuất hiện các dấu hiệu nhân tạo của giọng nói tổng hợp [7].

Ngoài các đặc trưng thủ công, nghiên cứu này còn sử dụng Wav2Vec 2.0, một mô hình học tự giám sát cho phép trích xuất các biểu diễn ngữ âm có tính khái quát cao trực tiếp từ tín hiệu âm thanh thô [3]. Các biểu diễn này chứa thông tin ngữ âm và ngữ điệu quan trọng, đặc biệt hữu ích đối với các ngôn ngữ có thanh điệu như tiếng Việt.

Trên cơ sở các đặc trưng nói trên, nghiên cứu sử dụng các thuật toán học máy và học sâu bao gồm Support Vector Machine (SVM), XGBoost và Multi-Layer Perceptron (MLP). SVM là mô hình phân loại dựa trên siêu phẳng tối ưu, XGBoost là thuật toán tăng cường dựa trên cây quyết định, trong khi MLP là mạng nơ-ron truyền thẳng có khả năng học các quan hệ phi tuyến giữa các đặc trưng đầu vào và nhãn đầu ra.

3 PHƯƠNG PHÁP NGHIÊN CỨU VÀ DỮ LIỆU

3.1 Xây dựng bộ dữ liệu

Bộ dữ liệu thực nghiệm được xây dựng gồm 2.400 tệp âm thanh tiếng Việt, trong đó có 1.200 mẫu giọng nói thật và 1.200 mẫu giọng nói giả mạo, tạo thành một tập dữ liệu cân bằng giữa hai lớp.

Giọng nói thật được thu thập từ bộ dữ liệu mã nguồn mở VIVOS/VLSP, bao gồm các đoạn ghi âm tự nhiên của nhiều người nói đến từ các vùng miền khác nhau của Việt Nam [4]. Giọng nói giả mạo được tổng hợp từ các nền tảng trí tuệ nhân tạo phổ biến như FPT.AI, Viettel AI và ElevenLabs.

Việc sử dụng nhiều công nghệ tổng hợp giọng nói khác nhau giúp tăng tính đa dạng của dữ liệu giả mạo, từ đó

giảm sự phụ thuộc của mô hình vào một nguồn sinh cụ thể và cải thiện khả năng khái quát hóa khi áp dụng trong thực tế.

3.2 Tiền xử lý và trích xuất đặc trưng (Feature Engineering)

Trong các hệ thống học máy xử lý âm thanh, giai đoạn tiền xử lý và trích xuất đặc trưng đóng vai trò quan trọng đối với hiệu năng của mô hình. Tín hiệu âm thanh thô thường có độ dài không đồng nhất, chứa khoảng lặng và có thể chịu ảnh hưởng của nhiễu môi trường. Do đó, nghiên cứu thực hiện quy trình chuẩn hóa dữ liệu nhằm đưa toàn bộ tệp âm thanh về cùng một định dạng trước khi trích xuất các đặc trưng trong miền thời gian – tần số, bao gồm MFCC và Mel-Spectrogram [5].

3.2.1 Quy trình tiền xử lý và chuẩn hóa dữ liệu

Mục tiêu của giai đoạn này là đưa toàn bộ tệp âm thanh về một định dạng thống nhất nhằm đảm bảo tính nhất quán cho quá trình huấn luyện và đánh giá mô hình. Cụ thể, tất cả dữ liệu được chuẩn hóa về tần số lấy mẫu 16.000 Hz, dạng đơn kênh (mono) và thời lượng cố định 5 giây cho mỗi tệp.

Quy trình tiền xử lý được thực hiện bằng thư viện Librosa [5] và bao gồm các bước sau:

- **Loại bỏ khoảng lặng (Trimming):** Sử dụng hàm `librosa.effects.trim` với ngưỡng `top_db=20` để loại bỏ các đoạn im lặng ở đầu và cuối tệp, giúp tập trung vào phần tín hiệu chứa thông tin hữu ích.
- **Cố định độ dài (Fix Length):** Các tệp có thời lượng ngắn hơn 5 giây được bổ sung giá trị 0 (padding), trong khi các tệp dài hơn 5 giây được cắt bớt (truncating).
- **Lưu trữ và lập chỉ mục:** Dữ liệu sau khi xử lý được lưu dưới định dạng `.wav`. Đồng thời, một tệp `metadata.csv` được tạo để quản lý nhãn phân loại (Real: 0, AI: 1) và các thông tin liên quan đến dữ liệu.

3.2.2 Trích xuất đặc trưng

Sau khi hoàn tất quá trình tiền xử lý, nghiên cứu trích xuất hai loại đặc trưng âm học chính là MFCC và Mel-Spectrogram [5].

- **MFCC (Mel-Frequency Cepstral Coefficients):** MFCC là tập đặc trưng mô phỏng cách hệ thính giác của con người cảm nhận tín hiệu âm thanh. Trong nghiên cứu này, mỗi tệp âm thanh được biểu diễn bằng 40 hệ số MFCC. Trên trục thời gian, ma trận đặc trưng được chuẩn hóa về kích thước cố định gồm 157 khung thời gian (frames) thông qua kỹ thuật padding hoặc truncating.

- **Mel-Spectrogram:** Mel-Spectrogram biểu diễn sự phân bố năng lượng của tín hiệu theo thời gian và tần số trên thang Mel. Năng lượng phổ được chuyển đổi sang đơn vị decibel (dB) bằng hàm `power_to_db`, giúp làm nổi bật sự khác biệt giữa các dải năng lượng và hỗ trợ quá trình học của mô hình.

Việc sử dụng đồng thời MFCC và Mel-Spectrogram cung cấp các biểu diễn đặc trưng bổ sung cho nhau, tạo cơ sở để đánh giá hiệu quả của các mô hình học máy và học sâu trên cùng một bộ dữ liệu.


3.3 Trực quan hóa và phân tích đặc trưng

Giai đoạn này nhằm trực quan hóa tín hiệu âm thanh để quan sát sự khác biệt giữa giọng nói thật và giọng nói giả mạo trên ba khía cạnh chính: miền thời gian, miền tần số và cao độ (pitch).

3.3.1 Phân tích đặc trưng sinh học và ngữ điệu

MFCC (Mel-Frequency Cepstral Coefficients): Biểu đồ MFCC của giọng nói thật và giọng nói giả mạo có cấu trúc tương đối giống nhau, cho thấy các hệ thống tổng hợp hiện nay đã mô phỏng tốt đặc trưng âm sắc. Tuy nhiên, ở các hệ số cao, giọng nói thật thể hiện sự biến thiên linh hoạt hơn.

Đường viền cao độ (Pitch/F0 Contour): Giọng nói thật có sự thay đổi cao độ liên tục và mềm mại, phản ánh ngữ điệu tự nhiên. Trong khi đó, giọng nói giả mạo xuất hiện nhiều đoạn cao độ ổn định kéo dài và các điểm ngắt quãng, cho thấy sự thiếu hụt các dao động vi mô đặc trưng của giọng người.




Hình 3.3.1: Phân tích đặc trưng sinh học và ngữ điệu

3.3.2 Phân tích hình thái sóng và năng lượng tần số

Biểu đồ dạng sóng (Waveform): Biểu đồ dạng sóng biểu diễn biên độ tín hiệu theo thời gian và được sử dụng để đánh giá tính ổn định của tín hiệu âm thanh. Kết quả cho thấy giọng nói giả mạo có biên độ dày đặc hơn và cường độ lớn hơn, với nhiều đoạn đạt giá trị gần mức 1.0. Ngoài ra, thời lượng của mẫu giọng giả (khoảng 4,4 giây) dài hơn so với mẫu giọng thật (khoảng 3,2 giây), phản ánh sự khác biệt về nhịp điệu và tốc độ phát âm.

Mel-Spectrogram: Mel-Spectrogram biểu diễn sự phân bố năng lượng của tín hiệu trên miền thời gian – tần số theo thang đo Mel. Cả hai loại tín hiệu đều thể hiện rõ các dải formant chính. Tuy nhiên, phổ của giọng nói giả mạo có xu hướng đều hơn và các đường vân phổ sắc nét hơn, trong khi giọng nói thật xuất hiện nhiều biến thiên tự nhiên giữa các dải tần do ảnh hưởng của hơi thở và nhiều môi trường.



Hình 3.3.2: Phân tích hình thái sóng và năng lượng tần số

Kết luận chung: Sự khác biệt rõ rệt nhất được quan sát ở đường viền cao độ và phân bố biên độ tín hiệu. Đây là những đặc trưng quan trọng giúp mô hình phân biệt giữa giọng nói thật và giọng nói giả mạo.

3.4 Trích xuất đặc trưng chuyên biệt cho từng mô hình (Model-Specific Feature Extraction)

3.4.1 Đặc trưng chuyên biệt cho mô hình SVM

Nghiên cứu sử dụng LFCC (Linear Frequency Cepstral Coefficients) làm đặc trưng đầu vào cho mô hình Support Vector Machine (SVM), thay cho MFCC thường được sử dụng trong các hệ thống xử lý âm thanh.

Khác với MFCC sử dụng thang tần số Mel để mô phỏng đặc tính thính giác của con người, LFCC áp dụng bộ lọc tuyến tính, qua đó bảo toàn tốt hơn thông tin ở các dải tần số cao. Đây là khu vực thường chứa các dấu hiệu nhân tạo (synthetic artifacts) do các hệ thống tổng hợp giọng nói tạo ra.

Việc sử dụng LFCC giúp xây dựng một không gian đặc trưng phù hợp hơn cho bài toán phân loại, cho phép SVM xác định siêu phẳng phân tách tối ưu giữa hai lớp dữ liệu. Trước khi huấn luyện, toàn bộ đặc trưng được chuẩn hóa bằng phương pháp Z-score (Standard Scaler) nhằm đưa các chiều dữ liệu về cùng thang đo và giảm ảnh hưởng của sự chênh lệch phương sai giữa các đặc trưng.

3.4.2 Đặc trưng chuyên biệt cho mô hình XGBoost

Đối với XGBoost, một biểu diễn đặc trưng riêng được xây dựng nhằm tận dụng khả năng xử lý dữ liệu dạng bảng của thuật toán này. Thay vì sử dụng trực tiếp ma trận đặc trưng có kích thước 40×157 , nghiên cứu thực hiện hai bước biến đổi chính:

- **Bổ sung đặc trưng động học:** Từ ma trận đặc trưng ban đầu, các đạo hàm bậc một (Delta) và bậc hai (Delta-Delta) được tính toán để mô tả tốc độ và gia tốc biến thiên của tín hiệu. Nhờ đó, số lượng đặc trưng được mở rộng từ 40 lên 120 cho mỗi khung thời gian.
- **Nén theo thống kê (Statistical Pooling):** Trên mỗi dải đặc trưng, bốn đại lượng thống kê gồm giá trị trung bình (Mean), độ lệch chuẩn (Standard Deviation), giá trị lớn nhất (Max) và giá trị nhỏ nhất (Min) được tính theo trục thời gian.

Sau quá trình biến đổi, mỗi tệp âm thanh được biểu diễn bằng một véc-tơ một chiều gồm 480 đặc trưng. Biểu diễn này giúp XGBoost khai thác hiệu quả các đặc trưng âm học quan trọng và nâng cao khả năng phân biệt giữa giọng nói thật và giọng nói giả mạo.

3.4.3 Đặc trưng chuyên biệt cho mô hình MLP

Các đặc trưng thủ công như MFCC và LFCC chủ yếu phản ánh đặc tính âm học bề mặt của tín hiệu và chưa biểu diễn đầy đủ thông tin ngữ âm và ngữ điệu. Để khai thác các đặc trưng sâu hơn, nghiên cứu sử dụng Wav2Vec 2.0 [3] như một bộ trích xuất đặc trưng cho mô hình Multi-Layer Perceptron (MLP).

Wav2Vec 2.0 là mô hình học tự giám sát được tiền huấn luyện trên quy mô lớn, có khả năng tạo ra các véc-tơ nhúng (embeddings) kích thước 768 chiều từ tín hiệu âm thanh thô. Các véc-tơ này chứa thông tin ngữ âm, cao độ và các đặc điểm ngữ điệu của giọng nói.

Các embedding được sử dụng làm đầu vào cho mô hình MLP. Sự kết hợp giữa các biểu diễn ngữ âm có tính khái quát cao và các lớp ẩn phi tuyến giúp mô hình nâng cao khả năng phân biệt giữa giọng nói thật và giọng nói giả mạo.

3.5 Huấn luyện mô hình

Quá trình huấn luyện các bộ phân lớp được thực hiện trên tập dữ liệu đã qua tiền xử lý, với tỷ lệ phân chia ngẫu nhiên là 80% cho tập huấn luyện (Train set: 1918 mẫu) và 20% cho tập kiểm thử (Validation/Test set: 480 mẫu). Các tham số huấn luyện được thiết lập cụ thể cho từng kiến trúc thuật toán như sau:

3.5.1 Mô hình SVM

Nghiên cứu tiến hành huấn luyện hai biến thể độc lập của mô hình SVM trên hai không gian đặc trưng riêng biệt: MFCC và LFCC. Quá trình tối ưu hoá mặt phẳng phân cách (hyperplane) được thực hiện với các thông số tiêu chuẩn để giải quyết tính phi tuyến phức tạp của dữ liệu sóng âm. Đặc trưng đầu vào được đồng bộ hóa biên độ thông qua phân phối chuẩn Z-score nhằm đảm bảo tốc độ hội tụ của thuật toán.

3.5.2 Mô hình XGBoost

Mô hình XGBoost được tối ưu siêu tham số bằng phương pháp Grid Search kết hợp với kiểm tra chéo 5-fold. Tổng cộng khoảng 300 cấu hình khác nhau được thử nghiệm để lựa chọn bộ tham số phù hợp nhất, bao gồm `max_depth=5`, `learning_rate=0.1`, `subsample=0.9` và `colsample_bytree=0.9`.

Trong quá trình huấn luyện, cơ chế Early Stopping được sử dụng để tự động dừng khi hiệu năng trên tập đánh giá không còn được cải thiện, với số lượng cây tối đa là 400. Sau khi xác định được bộ siêu tham số tối ưu, mô hình cuối cùng được huấn luyện lại trên toàn bộ tập huấn luyện.

3.5.3 Mô hình MLP

Mô hình Multi-Layer Perceptron (MLP) được huấn luyện trên hai loại đặc trưng đầu vào: MFCC (40 chiều) và các véc-tơ nhúng do Wav2Vec 2.0 tạo ra (768 chiều). Quá trình tối ưu sử dụng thuật toán huấn luyện với ngưỡng hội tụ `tol=0.0001` và cơ chế dừng sớm để tránh hiện tượng quá khớp.

Đối với đặc trưng MFCC, mô hình hội tụ sau 75 epoch. Với đặc trưng Wav2Vec 2.0, mô hình hội tụ nhanh hơn và dừng sau 22 epoch. Kết quả này cho thấy các embedding từ Wav2Vec 2.0 cung cấp biểu diễn đặc trưng hiệu quả hơn cho bài toán phân loại.

4 KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1 Đánh giá hiệu năng các mô hình cơ sở

Hiệu năng của 5 mô hình được đánh giá trên tập kiểm thử gồm 480 mẫu thông qua các chỉ số Accuracy, Precision, Recall và F1-Score. Kết quả được trình bày trong Bảng 1.

Kết quả trong Bảng 1 cho thấy mô hình SVM sử dụng đặc trưng LFCC đạt hiệu năng cao nhất với độ chính xác 89.38%. Kết quả này cho thấy việc sử dụng LFCC giúp mô hình khai thác hiệu quả các đặc trưng phổ ở dải tần số cao, vốn thường chứa các sai khác đặc trưng giữa giọng nói tự nhiên và giọng nói tổng hợp.

Xếp thứ hai là mô hình MLP sử dụng đặc trưng Wav2Vec 2.0 với độ chính xác 88.75%. Mặc dù thấp hơn mô hình tốt nhất 0.63 điểm phần trăm, kết quả này cho thấy các véc-tơ nhúng được trích xuất từ Wav2Vec 2.0 vẫn mang lại khả năng biểu diễn tốt đối với các đặc trưng ngữ âm và ngữ điệu của tiếng Việt.

Đối với các mô hình sử dụng đặc trưng MFCC, độ chính xác thu được dao động từ 84.58% đến 86.88%. Trong số này, XGBoost đạt kết quả cao nhất với độ chính xác 86.88%. Tuy nhiên, mô hình đạt độ chính xác 100% trên tập huấn luyện nhưng chỉ đạt 86.88% trên tập kiểm thử, cho thấy hiện tượng quá khớp vẫn còn tồn tại.

Nhìn chung, kết quả thực nghiệm cho thấy đặc trưng đầu vào có ảnh hưởng đáng kể đến hiệu năng của mô hình.

Bảng 1: So sánh hiệu năng phân loại của 5 mô hình học máy cơ sở

Kiến trúc Mô hình	Đặc trưng đầu vào	Accuracy	Precision (Fake)	Recall (Fake)	F1-Score	EER
SVM	LFCC	89.38%	0.89	0.90	0.89	0.1042
MLP	Wav2Vec 2.0	88.75%	0.90	0.87	0.89	0.1083
XGBoost	MFCC (Statistical)	86.88%	0.86	0.87	0.86	0.1250
MLP	MFCC	86.25%	0.85	0.88	0.86	0.1333
SVM	MFCC	84.58%	0.84	0.86	0.85	0.1542

Trong phạm vi nghiên cứu này, LFCC và Wav2Vec 2.0 cho kết quả tốt hơn MFCC, cho thấy đây là những hướng tiếp cận phù hợp cho bài toán phát hiện giọng nói giả mạo trong tiếng Việt.

4.2 Đánh giá hiệu năng hệ thống kết hợp mô hình

Mặc dù mô hình SVM sử dụng đặc trưng LFCC đạt kết quả cao nhất trong nhóm các mô hình cơ sở, việc sử dụng một mô hình duy nhất vẫn có thể dẫn đến sai số đối với những mẫu dữ liệu có đặc điểm khác biệt hoặc chứa nhiễu.

Để nâng cao độ ổn định của hệ thống, nghiên cứu xây dựng một mô hình kết hợp (Ensemble) theo phương pháp biểu quyết mềm (Soft Voting). Theo phương pháp này, xác suất dự đoán của 5 mô hình cơ sở được tổng hợp để đưa ra quyết định cuối cùng. Cách tiếp cận này cho phép tận dụng ưu điểm của các mô hình sử dụng những loại đặc trưng khác nhau, bao gồm LFCC, MFCC và Wav2Vec 2.0.

Kết quả thực nghiệm cho thấy hệ thống kết hợp cho hiệu năng ổn định hơn so với từng mô hình riêng lẻ. Việc tổng hợp kết quả dự đoán từ nhiều mô hình giúp giảm số lượng các trường hợp phân loại sai, đồng thời cải thiện khả năng tổng quát hóa trên các mẫu dữ liệu chưa gặp trong quá trình huấn luyện. Điều này cho thấy phương pháp kết hợp mô hình là một hướng tiếp cận phù hợp nhằm nâng cao độ tin cậy của hệ thống phát hiện giọng nói giả mạo.

4.3 Triển khai hệ thống và khả năng giải thích mô hình

Toàn bộ quy trình xử lý của hệ thống, bao gồm tiền xử lý dữ liệu, trích xuất đặc trưng, dự đoán bằng các mô hình cơ sở và kết hợp kết quả, đã được tích hợp vào một ứng dụng web phục vụ cho việc thử nghiệm và đánh giá trong thực tế.

Bên cạnh chức năng dự đoán, hệ thống còn được bổ sung cơ chế giải thích mô hình (eXplainable AI – XAI) dựa trên phương pháp SHAP (SHapley Additive exPlanations). Đối với mô hình XGBoost, thư viện SHAP được sử dụng để xác định mức độ đóng góp của từng đặc trưng vào kết quả phân loại. Kết quả được trực quan hóa dưới dạng biểu đồ Waterfall, cho phép người dùng quan sát những đặc trưng có ảnh hưởng lớn nhất đến quyết định của mô hình.

Việc tích hợp XAI giúp tăng tính minh bạch của hệ thống, đồng thời hỗ trợ người dùng hiểu rõ hơn cơ sở của từng dự đoán. Đây là yếu tố quan trọng nhằm nâng cao độ tin cậy và khả năng ứng dụng thực tiễn của hệ thống phát hiện giọng nói giả mạo.

4.4 Triển khai hệ thống và giao diện người dùng

Để kiểm chứng khả năng ứng dụng của mô hình, toàn bộ quy trình xử lý bao gồm tiền xử lý dữ liệu, trích xuất đặc trưng, dự đoán và kết hợp kết quả được tích hợp thành một ứng dụng web sử dụng thư viện Streamlit.

Hệ thống cho phép người dùng tải lên tệp âm thanh với các định dạng phổ biến như WAV, MP3 và M4A. Dữ liệu đầu vào sau đó được chuẩn hóa về tần số lấy mẫu 16 kHz và chuyển về dạng mono. Tiếp theo, hệ thống thực hiện trích xuất đặc trưng (MFCC, LFCC và Wav2Vec 2.0) và đưa qua các mô hình đã huấn luyện để thực hiện phân loại. Kết quả cuối cùng được tổng hợp từ nhiều mô hình theo cơ chế kết hợp.

Giao diện hệ thống được thiết kế gồm hai phần chính. Phần thứ nhất hiển thị kết quả dự đoán của hệ thống, bao gồm nhãn phân loại và xác suất dự đoán của từng mô hình, giúp người dùng quan sát mức độ nhất quán giữa các mô hình. Phần thứ hai cung cấp chức năng giải thích kết quả dựa trên phương pháp SHAP, trong đó mức độ ảnh hưởng của các đặc trưng được trực quan hóa nhằm hỗ trợ phân tích kết quả dự đoán.

Việc triển khai dưới dạng ứng dụng web giúp hệ thống dễ dàng kiểm thử trên dữ liệu thực tế và tạo điều kiện thuận lợi cho việc đánh giá tính ứng dụng của mô hình trong các kịch bản thực tế.

5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6 DANH MỤC TÀI LIỆU THAM KHẢO

Tài liệu

- [1] <https://arxiv.org/pdf/2308.14970> Audio Deepfake Detection: A Survey (Yi, J. et al., 2023)
- [2] <http://www.asvspoof.org/> ASVspoof: The Automatic Speaker Verification Spoofing and Countermeasures Challenge (2019/2021)

- [3] <https://arxiv.org/abs/2006.11477> Wav2Vec 2.0: A Framework for Self-Supervised Learning of Speech Representations (Baevski et al., 2020)
- [4] <https://vlsp.org.vn/> Cộng đồng và Dữ liệu VLSP (Vietnamese Language and Speech Processing)
- [5] <https://librosa.org/doc/latest/feature.html> Documentation chính thức của thư viện Librosa (Audio and Music Signal Analysis in Python)
- [6] <https://www.scitepress.org/Papers/2025/139119/139119.pdf> A Survey on Deep Fake Audio Detection Using Deep Learning (2025)
- [7] <https://ieeexplore.ieee.org/abstract/document/9996362> Deepfake Audio Detection via MFCC Features Using Machine Learning (2022)
- [8] <https://www.sciencedirect.com/science/article/pii/S1877050923002910> The Effect of Deep Learning Methods on Deepfake Audio Detection for Digital Investigation (2023)
- [9] <https://arxiv.org/abs/2401.05614> Self-Attention and Hybrid Features for Replay and Deep-Fake Audio Detection (2024)
- [10] <https://arxiv.org/abs/2406.08052> FakeSound: Deepfake General Audio Detection (2024)

PHỤ LỤC PHÂN CÔNG CÔNG VIỆC

7 Mô hình quản lý và phân công nhiệm vụ

Nghiên cứu này được triển khai theo phương pháp luận quản lý dự án linh hoạt (Agile/Scrum). Khối lượng công việc tại các giai đoạn nền tảng (Thu thập, Tiền xử lý dữ liệu và Thiết kế kiến trúc Hệ thống Dung hợp) được thực hiện song song và phân bổ đồng đều cho toàn bộ các thành viên. Ở giai đoạn Mô hình hóa và Tối ưu thuật toán chuyên sâu, nhiệm vụ được chuyên môn hóa như sau:

- Nguyễn Bá Hiên: Chịu trách nhiệm nghiên cứu, thiết kế trích xuất đặc trưng LFCC và tinh chỉnh siêu tham số (Hyperparameter tuning) cho kiến trúc mô hình không gian tuyến tính Support Vector Machine (SVM).
- Nguyễn Thị Hiền: Phụ trách nghiên cứu, kiểm soát hiện tượng quá khớp (overfitting) trên nền tảng cây quyết định XGBoost, đồng thời chịu trách nhiệm chính trong việc lập trình tích hợp phân hệ Trí tuệ nhân tạo có thể giải thích (eXplainable AI - SHAP) vào giao diện hệ thống.
- Nguyễn Tiến Hoan: Đảm nhận mảng Học sâu (Deep Learning), chịu trách nhiệm nghiên cứu cơ chế Học tự giám sát của Wav2Vec 2.0, chuyển giao véc-tơ nhúng và xây dựng thành công kiến trúc mạng nơ-ron truyền thẳng (Multi-Layer Perceptron - MLP).

8 Cập nhật tiến độ thực hiện hiện tại

Tính đến thời điểm báo cáo, nhóm nghiên cứu đã hoàn thành gần hết các mục tiêu cột lõi (Milestones) đã đề ra trong kế hoạch ban đầu, bao gồm:

- Thu thập và chuẩn hóa thành công bộ dữ liệu âm thanh song ngữ quy mô lớn.
- Huấn luyện và đánh giá thành công 5 biến thể thuật toán học máy và học sâu cơ sở.
- Xây dựng thành công cơ chế Dung hợp mô hình biểu quyết mềm (Ensemble Soft-Voting) để tối đa hóa độ chính xác tổng thể.
- Đóng gói toàn bộ đường ống thuật toán thành một ứng dụng web (Web-based Application) hoàn chỉnh mang tên "Viet-Guard" bằng thư viện Streamlit, tích hợp đầy đủ khả năng cảnh báo thời gian thực và phân tích pháp y kỹ thuật số (XAI).

9 Dự kiến kế hoạch thực hiện:

Mặc dù hệ thống "Viet-Guard" đã chứng minh được hiệu năng phân loại vượt trội trên tập dữ liệu hiện tại, nhóm nghiên cứu đề xuất các định hướng phát triển tiếp theo nhằm đưa mô hình tiến gần hơn tới tiêu chuẩn của một

công trình nghiên cứu khoa học có thể công bố quốc tế.

Xây dựng bộ dữ liệu chuẩn quy mô lớn - ViSpoofDB: Bộ dữ liệu 2,400 mẫu hiện tại, mặc dù đủ để thử nghiệm mô hình cơ sở, vẫn còn hai hạn chế cốt lõi: quy mô nhỏ và phân phối cân bằng nhân tạo (50/50) không phản ánh thực tế. Quan trọng hơn, hiện chưa tồn tại một benchmark công khai nào cho bài toán anti-spoofing tiếng Việt.

Lưu ý: Toàn bộ 2,000 mẫu từ nhóm Diffusion-based Vocoder (VALL-E X, VoiceBox) được giữ lại hoàn toàn để làm tập kiểm thử ngoài phân phối (unseen test set). Không một mẫu nào từ nhóm này được đưa vào training.

Phân chia tập dữ liệu:: Tổng 10k mẫu

- Training: 6,400 mẫu (80% của 8,000 mẫu seen)
- Test seen: 1,600 mẫu (20% của 8,000 mẫu seen)
- Test unseen: 2,000 mẫu (100% Diffusion-based chưa thấy trong training)

Bổ sung đặc trưng nhận biết thanh điệu (Tone-Aware Features): Tiếng Việt có 6 thanh điệu với đường viền F0 đặc trưng riêng biệt. Phân tích dữ liệu sơ bộ (Mục 3.3) đã chỉ ra rằng đường viền cao độ (Pitch/F0) là nơi có sự khác biệt rõ rệt nhất giữa giọng thật và giọng giả. Tuy nhiên, pipeline hiện tại chưa khai thác đặc trưng này một cách có hệ thống.

Chuyển sang Thang đo Đánh giá Chuẩn Quốc tế (EER): Thang đo Accuracy hiện tại có hai hạn chế: phụ thuộc vào ngưỡng phân loại được chọn tùy ý, và bị ảnh hưởng bởi phân phối lớp (tập 50/50 hiện tại không phản ánh thực tế). Trong khi đó, cộng đồng ASVspoof và Interspeech đều dùng Equal Error Rate (EER) điểm ngưỡng nơi tỉ lệ False Acceptance Rate bằng False Rejection Rate làm thang đo chính.

Đánh giá độ bền vững ngoài phân phối: Sau khi huấn luyện lại mô hình trên ViSpoofDB 10K, chạy đánh giá riêng biệt trên test_unseen (VALL-E X / VoiceBox) và so sánh EER. Nếu gap < 5%, mô hình học được đặc trưng phổ quát. Nếu gap > 10%, cần điều tra xem mô hình đang overfit theo nguồn hay theo kỹ thuật cụ thể. Kết quả dù tốt hay xấu đều có giá trị khoa học để phân tích.

Mô phỏng điều kiện thực tế (Real-world Noise Augmentation): Trong thực tế, giọng lừa đảo đến qua điện thoại, Zalo, Facebook với nén codec, tiếng ồn nền, và biến dạng tín hiệu, rất khác với dữ liệu sạch 16kHz hiện tại. Đánh giá mô hình trên cả hai điều kiện (clean và noisy) để báo cáo độ suy giảm hiệu năng, điều này trực tiếp chứng minh tính thực tiễn của hệ thống.

Tối ưu hoá tài nguyên tính toán (Model Quantization): Mô hình Wav2Vec 2.0 hiện tại đòi hỏi dung lượng bộ nhớ lớn (360MB). Giai đoạn tiếp theo sẽ áp dụng các kỹ thuật lượng tử hóa (INT8 Quantization) và cắt tỉa trọng số

Nhóm kỹ thuật	Nguồn	Số mẫu	Vai trò
Giọng thật	VIVOS, VLSP	2,000	Baseline bona fide
Neural TTS thương mại VN	FPT.AI, Viettel AI	2,000	Sát thực tế lừa đảo tại VN
Voice Cloning zero-shot	ElevenLabs, Azure TTS	2,000	Mối đe dọa hiện đại nhất
Open-source TTS	Coqui XTTS, Bark	2,000	Công cụ kẻ tấn công tự chạy
Diffusion-based Vocoder	VALL-E X, VoiceBox	2,000	Thế hệ mới nhất — tập unseen

Bảng 2: Cấu trúc dữ liệu mục tiêu

(Pruning) nhằm thu nhỏ kích thước xuống dưới 100MB và giảm độ trễ suy luận (inference time) xuống dưới 1 giây để đáp ứng tiêu chuẩn xử lý các luồng gọi thoại trực tiếp (live calls).

Triển khai ứng dụng thương mại (Deployment Integration): Nghiên cứu mở rộng việc tích hợp hệ thống

phân tích lỗi dưới dạng một Tiện ích mở rộng trình duyệt (Browser Extension) hoặc Giao diện lập trình ứng dụng (API Service). Định hướng này cho phép hệ thống tự động quét, phân tích phổ âm thanh và phát ra các cảnh báo trực tiếp khi người dùng nghe các tin nhắn thoại đáng ngờ trên các nền tảng mạng xã hội (Facebook, Zalo).